Panacée : revue critique des quatre phases du criblage moléculaire anti-VIH

Synthèse des artefacts Jupyter et des résultats numériques archivés · 9 novembre 2026 · Projet Panacée

Résumé

Ce rapport reconstitue la chaîne de calcul allant du pré-entraînement sur ZINC au criblage virtuel de Phase 4. Il distingue les observations tirées des journaux et checkpoints, les comparaisons entre versions du modèle et les hypothèses biologiques non testées. Le modèle VIH retenu, A'' (GNN propre et quatre forêts aléatoires augmentées), reproduit une ROC-AUC de 0,6201, une PRC-AUC de 0,1541 et le classement de 32 antirétroviraux sur 34 dans le décile supérieur d'un pool défini. Ce dernier résultat est un test de reconnaissance de médicaments connus, non une efficacité cellulaire mesurée des candidats. La Phase 4 fournit 124 structures ZINC et six entrées de repurposing après filtrage informatique ; aucune n'a encore été confirmée dans ce projet par un essai indépendant.

La progression apparente du rappel DrugBank s'accompagne d'une baisse de plusieurs métriques sur le test HIV par rapport au comparateur A du même rapport. Des fichiers antérieurs donnent des valeurs différentes pour ce comparateur ; ces versions ne sont pas fusionnées. La sélection d'un composé prometteur exige désormais des mesures antivirales et cytotoxiques indépendantes, puis une confirmation de la résistance, de la pharmacologie et de la sécurité.

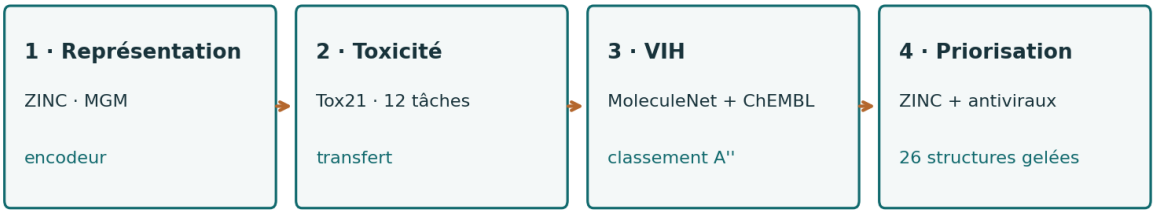


Figure 1. Parcours documentaire des quatre phases. Les flèches indiquent un transfert de représentation ou de résultats, non une validation biologique.

Périmètre, sources et méthode

L'analyse repose sur les journaux live_metrics.jsonl des Phases 1 à 3, les métadonnées des checkpoints retenus, les rapports JSON de comparaison, les CSV de hits et le registre SHA-256 du modèle A''. Les courbes ont été retracées à partir des enregistrements par époque ; les tableaux n'assemblent des modèles que lorsque leurs valeurs proviennent du même rapport comparatif. Les splits HIV Jupyter sont présents localement et leurs empreintes concordent avec le registre. Le test HIV compte 3 778 molécules, dont 84 positives. Les proportions et scores de classement sont conditionnels à cette population et à ses définitions de label [1].

1. Pré-entraînement moléculaire : Phase 1

La Phase 1 apprend une représentation moléculaire par masked graph modeling sur ZINC. Le checkpoint sovereign_encoder_v1.pth possède six couches d'attention et une dimension cachée de 256. Le journal contient 113 époques observées, bien que 3 000 aient été configurées ; ce nombre configuré ne doit pas être présenté comme le nombre exécuté. L'époque 98, retenue dans le checkpoint, porte une perte de validation de 0,1141. L'exactitude de validation atteint son maximum observé à l'époque 104 (0,9561).

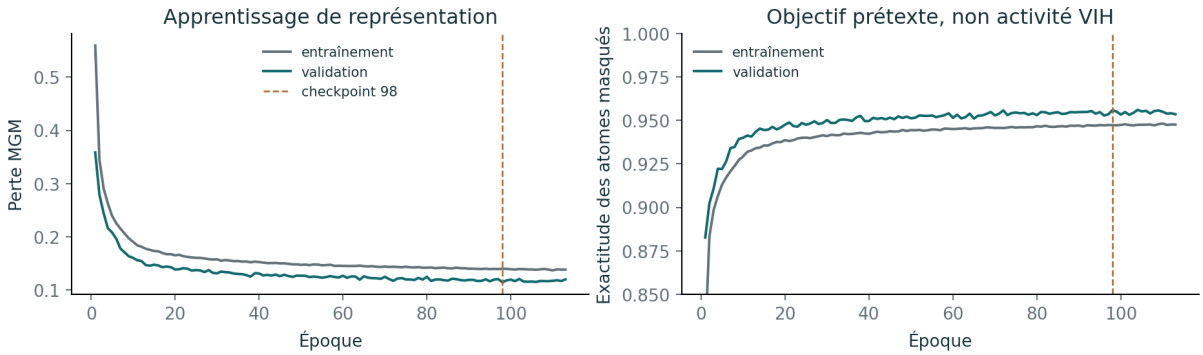


Figure 2. Évolution de la perte MGM et de l'exactitude des atomes masqués, 113 époques enregistrées. La ligne verticale situe le checkpoint de l'époque 98. Source : checkpoints/phase1/live_metrics.jsonl.

L'amélioration de l'objectif prétexte témoigne d'un apprentissage de la tâche de reconstruction, pas d'une capacité à prédire l'inhibition du VIH. L'absence d'évaluation externe spécifique de cette représentation empêche d'attribuer le gain ultérieur à la seule Phase 1. Le champ best_val_loss du checkpoint (0,1161) diffère de sa perte de validation enregistrée (0,1141) ; le présent rapport retient la valeur mesurée à l'époque 98 et signale l'écart de sérialisation.

2. Transfert toxicologique : Phase 2

La Phase 2 adapte l'encodeur aux 12 tâches Tox21. Le journal conserve 61 époques, contre 800 programmées. Le checkpoint sélectionné correspond à l'époque 41 : ROC-AUC macro de validation 0,7533, F1 0,3036, rappel 0,6544 et score de sélection 0,6489. La ROC-AUC du journal augmente encore jusqu'à 0,7642 à l'époque 61, mais la sélection n'était pas fondée sur cette seule métrique ; le score composite de sélection culmine à l'époque 41. La sensibilité macro, en revanche, passe de 0,7214 à l'époque 8 à 0,5979 à l'époque 61.

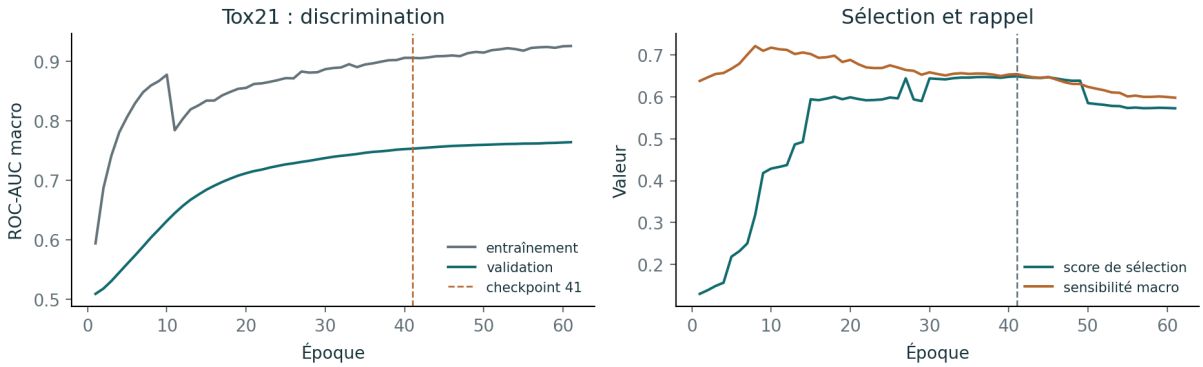


Figure 3. Trajectoires d'apprentissage et de sélection Tox21. Le checkpoint de l'époque 41 n'est pas l'époque de ROC-AUC maximale observée. Source : checkpoints/phase2/live_metrics.jsonl.

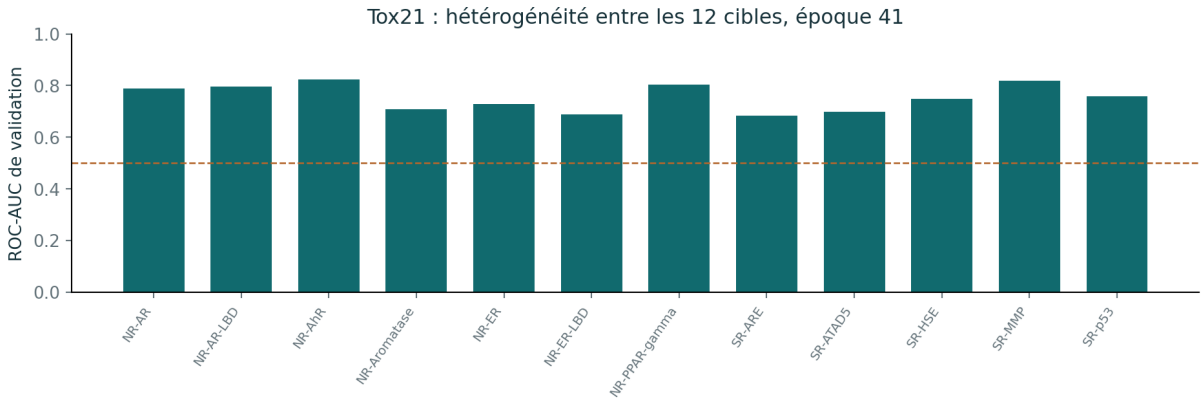


Figure 4. ROC-AUC de validation par tâche au checkpoint retenu. Les 12 endpoints ne présentent pas une performance uniforme ; les scores ne constituent pas une évaluation toxicologique du candidat VIH.

Les tâches Tox21 sont des proxys expérimentaux distincts. Ni la moyenne de ROC-AUC ni le checkpoint Phase 2 ne renseignent, à eux seuls, sur la fenêtre thérapeutique, la toxicité chronique, les interactions ou la sécurité clinique d'une structure priorisée [2].

3. Modélisation multipropriété et ensemble VIH : Phase 3

3.1 Modèle multipropriété initial

Le checkpoint panacee_phase3_complete.pth a été retenu à l'époque 13 parmi 38 époques enregistrées, sur un score composite multitâche de 0,6144. Sa ROC-AUC VIH est 0,7925 sur validation, mais 0,6568 sur le test ; la PRC-AUC VIH du test est 0,1665. Le rapport d'évaluation indépendant de ce checkpoint donne une ROC-AUC de classement de 0,6582, un EF@1 % de 16,57, une PRC-AUC de 0,1661 et seulement 15/34 ARV au gate DrugBank, sous le seuil interne de 25/34. La perte de validation croît fortement au fil des époques malgré une perte d'entraînement décroissante : le résultat final ne saurait être déduit de l'époque 38.

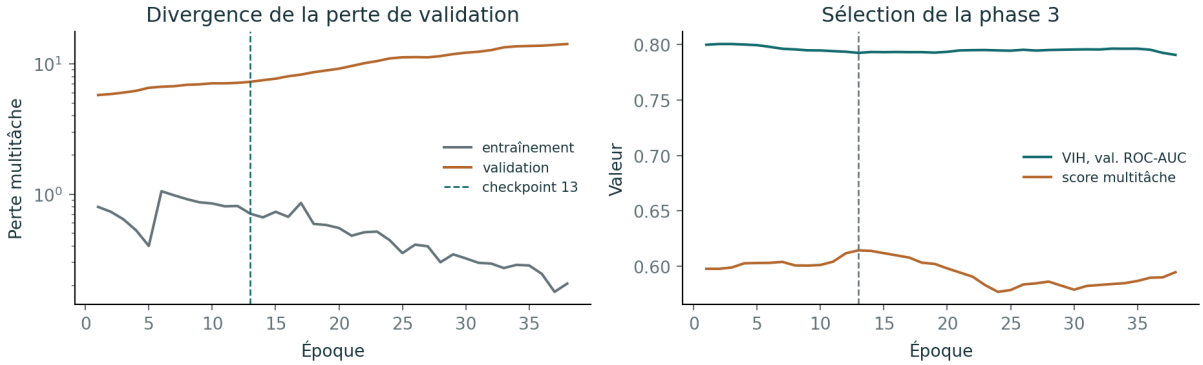


Figure 5. Phase 3 multipropriété : perte entraînement/validation en échelle logarithmique et critères de sélection. La ligne pointillée indique le checkpoint retenu (époque 13). Source : checkpoints/phase3/live_metrics.jsonl.

3.2 Exploration des représentations et échecs utiles

Les rapports de stacking comparent GNN, forêts sur ECFP4/ECFP6/MACCS/RDKit, fusion interne, métamodèle logistique et agrégation par rang. Le GNN seul de cette génération atteint une ROC-AUC test de 0,7194, mais une PRC-AUC de 0,1131 et 17/34 au gate. La forêt ECFP4 atteint 0,6524 de ROC-AUC, 0,1567 de PRC-AUC et 20/34. La fusion interne n'apporte pas le meilleur compromis de reconnaissance précoce ; l'agrégation de rang a été poursuivie. Ces chiffres concernent la génération antérieure, pas le GNN du paquet A" actuel. Le Model A de cette génération échoue au gate avec 24/34 dans push_ensemble_report.json. Le plafond a conduit à augmenter l'entraînement, plutôt qu'à annoncer un succès prématuré.

3.3 Augmentation ChEMBL et modèle A" retenu

Quinze mille cinq cent quatre-vingts structures actives ChEMBL ont été ajoutées à l'entraînement des forêts ; le GNN utilisé dans le manifeste A" reste le checkpoint propre déjà enregistré. Le filtre documenté exclut trois identités ARV, 146 composés partageant un scaffold avec validation/test, 36 analogues au-dessus du seuil Tanimoto 0,80 vis-à-vis des ARV et 77 doublons de train. Il demeure 189 ajouts partageant un scaffold avec un ARV. Deux des 34 ARV sont également des positifs connus du train MoleculeNet. Ces éléments imposent de distinguer un gate de reconnaissance de médicaments connus d'une validation externe totalement indépendante.

Le registre A" contrôle 12 artefacts. Le recalcul local à partir des poids et des 3 778 structures de test reproduit les huit métriques numériques du rapport augmented_report.json à la tolérance déclarée. Le tableau suivant provient exclusivement de ce rapport comparatif, afin de ne pas mêler des baselines de versions différentes.

Métrique, test HIV ou gate	A, même rapport	A" retenu
ROC-AUC	0.647	0.620
PRC-AUC	0.173	0.154

Métrique, test HIV ou gate	A, même rapport	A" retenu
EF@1 %	18.94	16.57
EF@5 %	5.95	5.00
BEDROC α=20	0.325	0.291
Hit rate top 100	0.23	0.20
Rappel top 10 %	0.321	0.321
Gate DrugBank	26/34	32/34

Tableau 1. Comparaison interne issue d'augmented_report.json ; les métriques du test et le gate DrugBank portent sur des populations et objectifs distincts.

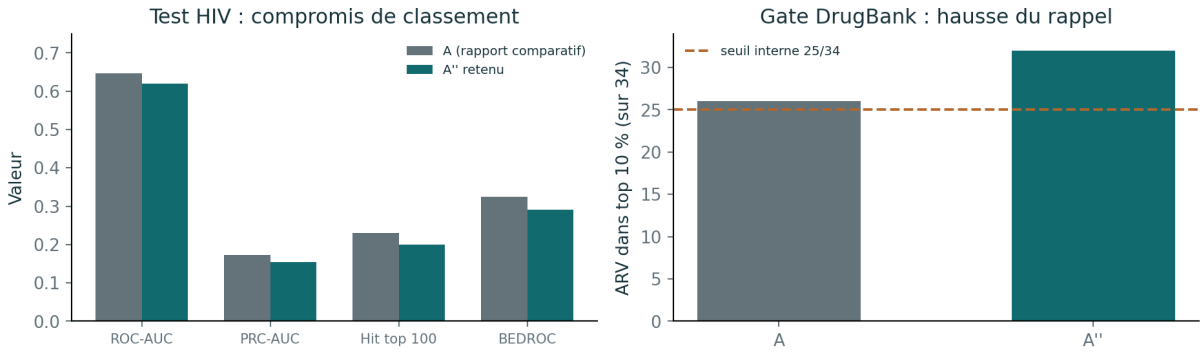


Figure 6. Comparaison interne A versus A" d'après un seul rapport (augmented_report.json). Le gain de rappel des ARV coexiste avec une baisse de ROC-AUC, PRC-AUC, BEDROC et hit rate top 100 sur le test HIV.

Le gain du gate est de 26 à 32/34 dans cette comparaison. Le coût sur le test HIV est mesurable : BEDROC passe de 0,325 à 0,291 et le hit rate top 100 de 0,23 à 0,20. Le bootstrap du rapport note un intervalle à 95 % de la différence BEDROC excluant zéro (−0,0686 à −0,0021) ; les intervalles du ROC-AUC et de la PRC-AUC recouvrent zéro. La hausse du gate ne suffit donc pas à conclure à une supériorité générale.

Un audit des cinq membres du paquet A" actuel retrouve, sur le même test, une PRC-AUC de 0,0776 pour le GNN, 0,1073 pour RF ECFP4 et 0,1541 pour l'ensemble. Le GNN de cette version diffère du GNN ancien à ROC-AUC 0,7194 ; les chiffres ne sont pas interchangeables. Les scores bruts ont des Brier scores de 0,039 à 0,140 contre 0,0217 pour la constante empirique de prévalence : le rang composite et les scores membres ne sont pas des probabilités calibrées. Le domaine d'applicabilité est calculé sur 49 150 empreintes train + augmentation ; la calibration conformal GNN couvre 93,09 % du test interne avec 67,44 % de sorties ambiguës. Cela ne démontre pas une couverture prospective.

Membre actuel	ROC-AUC	PRC-AUC	Précision top 100
GNN	0.576	0.078	0.17
RF ECFP4	0.597	0.107	0.18
RF ECFP6	0.586	0.095	0.13
RF MACCS	0.672	0.088	0.12
RF RDKit	0.625	0.056	0.08
A" ensemble	0.620	0.154	0.20

Tableau 2. Audit des membres réellement chargés par A". Il ne doit pas servir à réajuster les poids sur ce test déjà examiné.

4. Criblage et sélection de structures : Phase 4

La bibliothèque ZINC compte 249 455 structures scorées selon son résumé de traitement. Deux mille lignes ont été annotées et 124 satisfont les critères de sortie du CSV propre. Le fichier repurposing conserve 500 lignes scorées et six hits propres. Ces nombres décrivent un filtrage informatique ; ils ne constituent pas des confirmations antivirales. Les 124 hits ZINC sont tous étiquetés in_domain_moderate par le pipeline historique ; 118 ont une sortie conformal ambiguous et six active. Les six hits repurposing portent tous uncertain. Les étiquettes ne sont ni des mesures de puissance ni des garanties de sécurité.

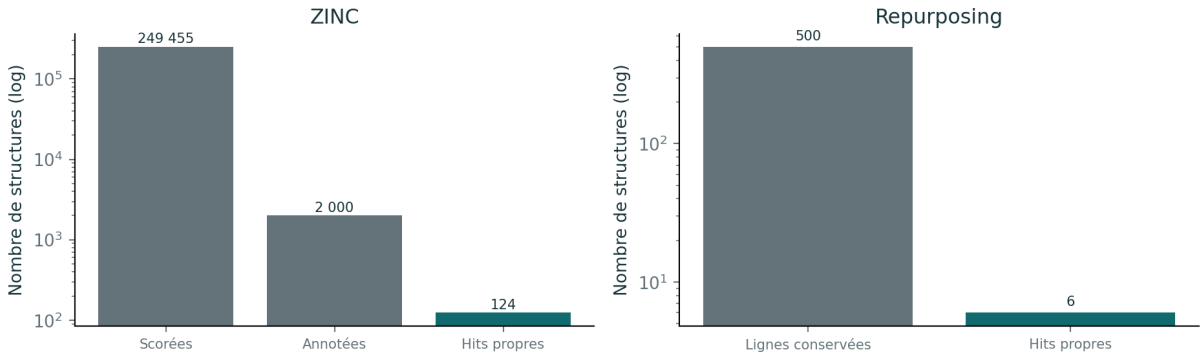


Figure 7. Entonnoir de Phase 4. Pour ZINC, les comptes proviennent du résumé de criblage et du CSV propre ; pour repurposing, « 500 lignes conservées » désigne le fichier archivé, non la taille certaine de la bibliothèque initiale. Échelle verticale logarithmique.

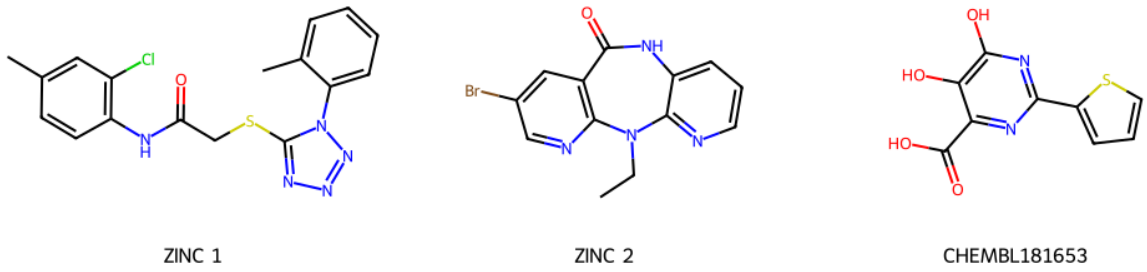


Figure 8. Représentations 2D calculées avec RDKit pour les deux premières lignes ZINC et la première ligne repurposing du CSV propre. Le dessin indique la connectivité déclarée par SMILES, non un mécanisme d'action ni une activité mesurée.

La médiane QED des 124 hits ZINC est 0,687, celle des six hits repurposing 0,555. QED et Lipinski sont des descripteurs, tandis que les colonnes de toxicité et d'ADMET du CSV sont des sorties de modèles. Leur présence ne transforme pas ces structures en candidats précliniques. Les cartes d'attention stockées pour 20 hits montrent des poids du modèle ; elles ne démontrent ni liaison à une cible du VIH ni pharmacophore causal.

Un paquet prospectif distinct a été gelé localement : 12 ZINC, six repurposing, quatre ARV de référence et quatre comparateurs négatifs du criblage MoleculeNet. Sa soumission aveugle, sa clé locale et ses prédictions ont des empreintes SHA-256. Aucun résultat expérimental n'a été reçu ; les quatre comparateurs ne sont pas des contrôles négatifs certifiés pour un essai biologique.

Discussion : interprétation et points non résolus

Trois résultats structurent la décision. D'abord, le pré-entraînement et le transfert toxicologique ont produit des checkpoints documentés, mais leurs métriques ne valident pas l'usage antiviral ou la sécurité d'un nouveau composé. Ensuite, la Phase 3 a franchi le seuil interne de reconnaissance des ARV avec A", au prix d'une baisse de certaines métriques de classement HIV. Enfin, la Phase 4 a réduit des bibliothèques en listes testables, sans preuve cellulaire. Le choix d'A" est cohérent avec un objectif de rappel d'ARV connus, mais ne prouve pas qu'il maximise la découverte de nouvelles séries chimiques.

Plusieurs discordances documentaires interdisent une méta-analyse naïve : le Model A vaut 24/34 dans un rapport et 26/34 dans le rapport comparatif A/A" ; un autre audit d'honnêteté donne 31/34 pour A' alors que la reproduction actuelle donne 32/34 pour A". Le fichier phase3_eval.json contient BEDROC=1,0, incompatible avec reports/eval.json (0,2979) pour les autres métriques identiques ; la valeur 1,0 n'est pas retenue. Le checkpoint GNN

propre contient un test_report avec zéro positif et une ROC-AUC non définie sur un jeu de leurres : ce rapport ne peut pas être cité comme performance HIV. La validation croisée à cinq folds (ROC-AUC 0,8338 ± 0,0276) évalue une configuration de forêts différente ; elle ne constitue pas une validation indépendante du modèle A'' complet.

La publication du rapport suit une logique de traçabilité inspirée des principes de transparence des modèles prédictifs [3] et des critères OCDE de domaine d'applicabilité [4], sans revendiquer une conformité réglementaire. Pour un antirétroviral, les données précliniques pertinentes incluent activité cellulaire, cytotoxicité, mécanisme, résistance et interactions [2]. La puissance, la tolérance et la barrière à la résistance ont une portée clinique que le classement moléculaire ne mesure pas [5].

Conclusion

Le projet a atteint une étape de priorisation moléculaire traçable, pas celle de découverte d'un médicament VIH confirmé. La prochaine décision scientifique dépend d'un essai indépendant et aveugle des structures gelées, avec mesures d'activité et de cytotoxicité, contrôle qualité du laboratoire et confirmation des hits. Les données quantitatives ainsi obtenues permettront de définir un modèle vNext orienté vers la puissance et la sélectivité ; le test déjà utilisé pour sélectionner A'' ne doit pas servir de nouveau terrain d'optimisation.

Traçabilité et reproductibilité

Le registre du modèle du 6 novembre associe les poids, rapports et jeux Jupyter à des empreintes SHA-256. Le présent PDF a été produit par scripts/build_scientific_review.py, qui refuse sa génération si le registre, les splits HIV ou les huit métriques A'' reproduites divergent. Les figures proviennent exclusivement des journaux et des CSV indiqués dans leurs légendes.

Artefact	SHA-256 (préfixe)	Fonction
GNN propre	31d0fbeff516a19f	Membre A''
Manifest A''	0db6064795005f12	Version du paquet
Split HIV test	35cf356fc1d00897	Évaluation 3 778
Reproduction A''	6e5080fe821893f9	Huit métriques

Références scientifiques et réglementaires

[1] Wu Z et al. MoleculeNet: a benchmark for molecular machine learning. Chem Sci. 2018;9:513–530. DOI 10.1039/C7SC02664A. https://doi.org/10.1039/C7SC02664A

[2] US FDA. Division of Antivirals: information for pre-IND submissions. https://www.fda.gov/about-fda/cder-offices-and-divisions/division-antivirals-dav-information-pre-ind-submissions

[3] Collins GS et al. TRIPOD+AI statement. BMJ. 2024;385:e078378. DOI 10.1136/bmj-2023-078378. https://www.bmj.com/content/385/bmj-2023-078378

[4] OCDE. Guidance Document on the Validation of (Q)SAR Models, principe du domaine d'applicabilité. https://www.oecd.org/content/dam/oecd/en/publications/reports/2014/09/guidance-document-on-the-validation-of-quantitative-structure-activity-relationship-q-sar-models_g1ghcc68/9789264085442-en.pdf

[5] NIH. Principles of Antiretroviral Therapy, mise à jour 2026. https://clinicalinfo.hiv.gov/en/guidelines/hiv-clinical-guidelines-adult-and-adolescent-arv/principles-antiretroviral-therapy

Sources internes principales

checkpoints/phase{1,2,3}/live_metrics.jsonl ; checkpoints/phase{1,2,3}/*.pth ; reports/eval.json ; checkpoints/phase3_stacking/{push_ensemble_report,augmented_report,bootstrap_ci_report,kfold_cv_report,arv_leakage_report}.json ; checkpoints/model_A_prime_augmented/{registry,validation_reproduction}.json ; checkpoints/phase4/{library_hits.summary,library_hits_clean,repurposing_hits_clean}.*. Les valeurs A'' et les empreintes ont été revérifiées lors de la génération. Les données brutes d'entraînement et le paquet prospectif restent locaux et hors du PDF.